

ניתוח נתונים ממערכות עצביות
דוח 5: Analysis of Motor Imagery Data

מגישות:

יולי לוי/ 208687327

תם (מרים) אשד/ 207820713

29.07.2023

תוכן עניינים:

2	תוכן עניינים:
3	מבוא
4	שיטות
4	מהלך הניסוי:
4	שלב 1: ייבוא נתונים וויזואליזציה
4	שלב 2: Power Spectrum, spectrogram
5	שלב 3: features
5	power bands:
5	Covariance
6	spectral entropy:
6	שלב 4: Classification
6	NCA
7	שלב 5: Test the classifier
8	תוצאות
8	גרף 1-וויזואליזציה:
8	גרף 2- Power Spectra:
9	גרף 3- Power spectrogram:
9	גרף 4- Power bands:
11	גרף 5- PCA:
12	גרף 6- NCA:
14	דיון
14	כללי:
14	גלי אלפא:
14	גלי בטא:
15	גלי גמא:
15	Covariance:
15	Spectral entropy:
16	Feature classification:
17	ביבליוגרפיה

מבוא

טכנולוגיית (BCI) Brain-Computer Interface היא תחום מחקר המשמש לעיתים קרובות למחקר קליני, שיפור או תיקון של תפקודים קוגניטיביים, חושיים ומוטורים, למשל, ע"י שליטה על גפיים רובוטיות, VR ועוד. מטרתו לבסס ערוץ תקשורת ישיר בין המוח להתקנים חיצוניים.

תקשורת זו מתבצעת על ידי תרגום אותות מוח לפקודות, בעבודה זו האותות נלקחו בעזרת הקלטות EEG הנלקחות באופן חיצוני לא פולשני, בעזרת אלקטרודות המוצמדות לקרקפת הנבדק. כיום שיטה זו פופולרית, בין היתר גם לשימוש ב-BCI בשל בטיחותה בהשוואה לטכניקות הדמייה עצבית אחרות (כגון fMRI) המאפשרת שימוש על אוכלוסיות רבות ומגוונות (כגון קשישים ילדים ואוכלוסיות בריאות), עם סיכון מינימלי. בנוסף, תהליכים בקליפת המוח כוללים איתות חשמלי בין נוירונים המשתנים פעמים רבות בטווח של 10 אלפיות השנייה (0.01 שניות). EEG היא הטכנולוגיה הזמינה היחידה עם יכולת מעקב אחר השינויים הדינמיים המהירים הללו. עם זאת, יש להתייחס גם למגבלותיה של השיטה בשל היותה לא חודרנית, היא מקבלת אותות דרך הקרקפת, ולכן ניחנת ברזולוציה מרחבית נמוכה וברגישות רבה למקורות "רעש" (קלטי רקע הפוגעים באותות המוחיים שאנו מעוניינות להקליט) שונים, כגון תנועות עיניים ולכן יש לוודא "ניקוי" מקסימלי מרעשים לפני תחילת השימוש בהקלטות.

כיום שימוש ב-BCI נעשה בין היתר לזהות דפוסי תבניות במקצבים חושי-מוטוריים (**Motor Imagery BCI**) בעקבות דמיון של תנועת גוף. הוכח כי בעת דמיון הפעלת איברים שונים, ישנם תדרים בקליפת המוח המוטורית המגיבים באופן שונה. התגובות הנוירוליות משתנות בין אדם לאדם ולכן יש ללמוד תגובות באופן אינדיבידואלי. מטרת שיטה זו היא לזהות את דפוסים אלו ובעזרתם לבצע חיזוי של התנועה שהאדם מעוניין לבצע.

בעבודה זו בעזרת הקלטות שנלקחו בשיטת EEG, עם התייחסות לשתי אלקטרודות C3, C4 מנבדקים שהתבקשו לדמיין תנועה של יד ימין או שמאל ננסה לבודד פיצ'רים שיעזרו לנו לסווג את הפעילות המוחית של הנבדק ובכך לבצע חיזוי של איזו יד הנבדק דמיין שהוא מניע.

אנו **צופות** כי בעת דמיון תזוזה של יד ימין נראה פעילות מוגברת באלקטרודה C3 (המייצגת את האזור במוח הפועל בעת תזוזת יד ימין) ובהתאם נצפה להבחין בפעילות מוגברת באלקטרודה C4 בעת הפעלת יד שמאל. כמו כן, נצפה לראות פעילות מוגברת של תדרי אלפא (8-13 Hz) בצד הנגדי. בנוסף נצפה לשינוי בגלי בטא (13-30 Hz) ובגלי גמא (30-50 Hz) בהתאמה בין היד המדומיינת לאלקטרודה המייצגת אותה.

שיטות

מהלך הניסוי:

קובץ הנתונים שקיבלנו נלקח בשיטת EEG מאלקטרודות C3, C4 מנבדק יחיד ועבר הסרה של ארטיפקטים (רעש) בהקלטה. נמדדו אלקטרודות C3, C4 הממוקמות באזור המוטורי הראשוני שמעורב בפעולת המערכת המוטורית ומתפקד כמרכז השליטה הראשי על הפעילות המוטורית הרצונית בגוף. במהלך הניסוי הנבדק התבקש להתמקד במרכז המסך שלפני ולאחר מכן לדמיין תנועה של יד ימין / יד שמאל בהתאם לחצים שהוצגו לו לאחר השמעת צליל. מהלך זה חזר 160 פעמים (trials), מתוכם השתמשו ב-128 חזרות לאימון המודל והשאר לבחינת המודל. כל trial ערך 6 שניות, עם קצב הקלטה של 128 Hz, סך הכל ההקלטה מחולקת ל-768 מקטעים.

שלב 1: ייבוא נתונים וויזואליזציה

ייבוא נתונים: קובץ הנתונים שקיבלנו הכיל struct עם נתוני ההקלטות של הניסוי, ועוד מידע נלווה כמו תדר הדגימה ועוד. בשלב הראשון חילצנו מתוך קובץ זה את הנתונים הרלוונטיים לנו ואת קבצי ההקלטות מהאלקטרודות הרלוונטיות (C3, C4) ואת התוויות בשבילן. ויזואליזציה: על מנת לקבל תמונה ברורה יותר של הנתונים הגולמיים, בחרנו 20 חזרות אקראיות והצגנו את האות שהתקבל מכל אלקטרודה בחזרה זו. עשינו זאת עבור כל אחד ממצבי הדמיון המוטורי (ימין, שמאל).

שלב 2: Power Spectrum, spectrogram

בשלב זה רצינו לקבל Power-spectrum עבור כל אלקטרודה בכל מצב (דמיון מוטורי צד ימין ושמאל). בשביל זה השתמשנו בפונקציה *AveragePwelch* אשר מחשבת Power-spectrum בשיטת welch - שיטה שמחלקת את הדגימה לחלונות ומחשבת עבור כל חלון שכזה את העוצמה עבור כל תדר. הוצאנו ממוצע וסטיית תקן על מנת שנוכל להציג את התוצאות בצורה ברורה. חישובן את טווח העוצמה עבור כל תנאי (ימין, שמאל, בכל אלקטרודה) רק את הזמן שבו התבצע הדמיון המוטורי מכיוון שבו אנו נראה את ההבדל שיסייע בהמשך לסיווג וחישוב. Power-spectrum אינו כולל את מימד הזמן ומייצר ממוצע לאורך הדגימה. יצרנו גרף שמראה את התוצאות.

```
1 function [welchData, f] = AvaragePwelch(data, windowSize, overLap, nfft, FS)
2 %The function calculate power spectrum in Welch method and return the
3 %average power for each frequency and the std.
4 % inputs: data - the record from one electrode in one condition (left
5 % / right) in the motor imagery period. [64 * 481].
6 %windowSize - the size of a single window for the pwelch function
7 % overLap - the size of the over laps for the pwelch function
8 % nfft - the amount of samples in 1 trial, FS - frequency sample rate.
9 %outputs: welchData - the power spectrum mean amd std, f - frequency
10 %vector.
11 [welch, f] = pwelch(data, windowSize, overLap, nfft, FS);
12 stdWelch = std(welch',1);
13 meanWelch = mean(welch, 2);
14 welchData = [meanWelch,stdWelch'];
15 end
```

כעת, רצינו לקבל מפת חום של עוצמת התדר לאורך הניסוי מבלי לוותר על מימד הזמן. יצרנו עבור כל תנאי ממוצע על גבי החזרות והשתמשנו בפונקציית *spectrogram* כדי לקבל את טווח העוצמות בכל תדר לאורך כל הניסוי. חישובנו את ממוצע העוצמות בכל תנאי בשנייה הראשונה והחסרנו אותו מהנתונים של הספקטוגרמה. המטרה הייתה להפחית את ההשפעה של רעש ככל הניתן ואכן קיבלנו מפת חום ברורה שאפשרה לנו להבין באילו תדרים היה הבדל בין התנאים השונים. ניסינו גם לייצר

מפת חום ע"י החסרה של התנאי של שמאל מימין וקיבלנו תמונה ברורה אך פחות. לאחר מכן המרנו את הנתונים לדיציבלים כדי שנוכל לקבל מידע ברור ממפת החום.

```
150 %avarging the base lineover the time domain
151 meanBaseLinec3right = mean(powerC3Right(:,1:baseLinePeriod), 2);
152 meanBaseLinec4right = mean(powerC4Right(:,1:baseLinePeriod), 2);
153 meanBaseLinec3left = mean(powerC3Left(:,1:baseLinePeriod), 2);
154 meanBaseLinec4left = mean(powerC4Left(:,1:baseLinePeriod), 2);
155
156
157 powerC3Left = powerC3Left - meanBaseLinec3left;
158 powerC4Left = powerC4Left - meanBaseLinec4left;
159 powerC3Right = powerC3Right - meanBaseLinec3right;
160 powerC4Right = powerC4Right - meanBaseLinec4right;
```

שלב 3: features

יצרנו פונקציה בשם *featuresExtraction* המחשבת עבור המידע שהיא מקבלת את הערכים בכל feature שהבחנו שרלוונטי לנו ובנוסף לפי טווחי תדרים מוכרים (אלפא, בטא וגמא). הפונקציה מבצעת את הפעולות הבאות ומחזירה לבסוף עבור כל חזרה מטריצה עם הנתונים שנמצאו עבור כל אחד מהפיצ'רים.

power bands:

יצרנו פונקציה בשם *calculate_power_histogram* שמטרתה לקחת טווח זמן וטווח תדרים ולחשב את ה-power band של המקטע הספציפי בכל אלקטרודה, עם חלוקה בין דמיון יד ימין/שמאל. בחרנו לבדוק את מקטע גלי אלפא, מכיוון שציפינו לראות עליה באלקטרודה שלא תואמת את תנועת היד (לדוגמה- עליה בפעילות של C4 בעת דמיון הנעת יד ימין). בנוסף נעזרנו בהיסטוגרמה ובגרף הוויזואליזציה על מנת לאתר מקטעים שיכולים לעזור בסיווג בין דמיון הידיים, עם התייחסות לגלי בטא וגמא.

```
7 %calculate time range
8 time_range_start= time_range(1)*fs ;
9 time_range_end = time_range(end)*fs;
10
11 %calculate the powerband for the given frequency band
12 relavent_data = data(:,floor(time_range_start):floor(time_range_end))';
13 power_band = bandpower(relavent_data,fs, freq_band);
```

Covariance

על בסיס הנתונים של סטיית התקן שחישבנו בפונקציית *AveragePwelch* הבחנו כי בהפעלת יד ימין קיימת שונות גדולה בין 2 האלקטרודות לעומת אותו טווח נתונים ביד שמאל וממפות החום הבחנו כי השונות הגדולה ביותר היא בין שניות 4-6 ולכן חישבנו את השונות המשותפת בטווח הזה. איתחלנו משתנה חדש *covariance* ואז יצרנו לולאת for העוברת על כל 128 החזרות. בכל חזרה לקחנו את הנתונים בשניות הרלוונטיות ובדקנו את השונות המשותפת בעזרת *cov*, לאחר מכן הוספנו אותה ל*covariance* והצגנו אותה בהיסטוגרמה בעזרת פונקציית *create_histogram*

```
83 %% CSP - Common Spatial Patterns
84 %covariance:
85 time_start= 4*FS;
86 time_end= 6*FS;
87 covariance = zeros(1, nTrials);
88
89 % Compute covariance for each trial
90 for n = 1:nTrials
91     cov_all= cov(baseTrialC3(n,time_start:time_end ), baseTrialC4(n, time_start:time_end));
92     covariance(n) = cov_all(1,2);
93 end
```

spectral entropy:

פיצ'ר נוסף שהשתמשנו בו הוא אנטרופיה מרחבית. מדד לרמת המורכבות בהתפלגות התדרים של אות. פיצ'ר זה מכמת את מידת השונות והמגוון ברכיבים המרחביים של האות על פני טווח תדרים מסוים. ראינו כי השונות הגדולה ב-C3 הייתה בטווח התדרים - 10-40 ולעומת זאת באלקטרודה C4 השונות הגדולה הייתה בין 25 ל-35 Hz. השתמשנו בפונקציה *CalculateSpectralEntropy* אשר מחשבת power - spectrum עבור כל חזרה ולאחר מכן תוך שימוש בנוסחה המתאימה מחשבת את האנטרופיה המרחבית. כאשר יצרנו את ההיסטוגרמה ראינו כי ישנה הפרדה טובה בין התנאים אך בהמשך הבנו כי פיצ'ר זה לא הגיע לתוצאות גבוהות ב-NCA.

```
4 for trial = 1:nTrials
5     % Compute the power spectrum for each trial separately
6     welch = pwelch(imagiryData(trial,:), windowSize, overLap, frequencyRange, FS);
7     powerSpectrum(trial,:) = welch;
8 end
9 spectralEntropy = -sum(powerSpectrum .* log2(powerSpectrum),2);
```

שלב 4: Classification

מכיוון שכל אחד מהפיצ'רים קיבל את טווח הנתונים המתאים לו ולא טווח אחיד, השתמשנו בפונקציית *zscore* אשר מנרמלת את הנתונים כדי לאפשר השוואה ביניהם בצורה טובה. השלב הבא היה לבצע ניתוח גורמים ראשיים (PCA) על הפיצ'רים השונים כדי לנסות ולהפחית מימדים. השתמשנו בפונקציית *pca* כדי לחשב את הנתונים ויצרנו גרפים המתארים את פיזור הנתונים של הרכיבים הראשונים של הפיצ'רים. יצרנו גרף דו מימדי ותלת מימדי כדי לראות מהי יכולת ההפרדה בין התנאים השונים ועד כמה הפיצ'רים שלנו יעילים לסיווג.

NCA

על מנת לשפר את אלגוריתם הלמידה שלנו השתמשנו במסווג Neighborhood (NCA) Components Analysis. הפונקציה המבצעת את ה-NCA נקראת '*fscnca*' ומקבלת את הפיצ'רים יחד עם הערכים שלהם ואת התוויות שלהם.

בעזרת ה-NCA ניתן לזהות איזה קריטריונים הם הרלוונטים ביותר לחיזוי דמיון מוטורי ולהשתמש בהם ורק בהם. על מנת להבין כיאות את התוצאות הצגנו את המשקלים, המתארים את המשקל של כל קריטריון בתהליך הלמידה, בשתי דרכים: גרף וטבלה. ככל שהמשקל גבוה יותר כך התרומה שלו גדולה יותר בתהליך החיזוי.

בשלב זה ניגשנו לבצע את הסיווג עצמו, לשם כך בדקנו איזה פיצ'רים קיבלו ציונים הגבוהים מ-0.1 ב-NCA ובחרנו להשתמש רק בהם. כדי לבצע את האימון בשיטה הטובה ביותר ולקבל מידע מדויק על עד כמה הסיווג שלנו אמין השתמשנו בשיטת של *k-fold cross validation*. זוהי שיטה המחלקת את סט האימון שלנו ל-K קבוצות שונות ובכל פעם משתמשת ב-K-1 קבוצות לאימון ובקבוצה אחת כבדיקה של עד כמה הסיווג טוב (validation). בחרנו ב-K = 5 כי ראינו שככל שמחלקים את הנתונים ליותר תיקיות מקבלים רמת דיוק יותר גבוהה אך סטיית התקן גדלה מאוד כי בכל פעם הבדיקה נעשית על קבוצת דוגמאות קטנה, מה שמוביל להרבה שונות בין בדיקה לבדיקה.

% Training the classifier

```
feature_ind = find(feature_scores >= 0.1);
num_feats = 5;
best_features = normalizedData(:, feature_ind(1:num_feats));
```

יצרנו לולאה שעוברת על K התיקיות השונות ובכל פעם משתמשת בקבוצה קטנה של הנתונים לבדיקה ובשאר הנתונים לאימון על ידי שימוש בפונקציית *classify*, פונקציה המשתמשת במסווג לינארי. הקפדנו כי בכל ריצה של הלולאה הקבוצה של האימון וקבוצת החזרות שהיוותה את הבדיקה יהיו זרות לחלוטין כדי להימנע מ- *over fitting* - מצב שבו המסווג לומד להתאים טוב לנתונים של האימון אך שגיאת ההכללה שלו (היכולת של המסווג לנבא את התוויות הנכונות) גדולה. חישבנו ממוצע של אחוז הדיוק וגודל השגיאה בין הריצות השונות וכך קיבלנו את רמת הדיוק של המסווג בממוצע, עבור האימון. כדי לדעת כמה המסווג מבצע את הסיווג טוב בדקנו בכל סיבוב כמה אחוזים מהתוויות שהוא נתן לקובץ הבדיקה מתאימים לתוויות האמיתיות (מהו גודל שגיאת ההכללה) שיש לנו וחישבנו ממוצע על גבי זה. קיבלנו בממוצע שגיאת אימון והכללה של כ- 10%.

השתמשנו במסווג נוסף שאינו לינארי שנקרא SVM - Support Vector Machine. יש למסווג זה מספר יתרונות, כולל היכולת שלו לטפל בנתונים עם הרבה מימדים והחוסן שלו מפני *over - fitting*. יש לו יישומים בתחומים שונים כמו סיווג תמונות, סיווג טקסט, ביזאינפורמטיקה ועוד. על ידי שימוש בפונקציה *fitcsvm* יצרנו את המסווג וחישבנו את הדיוק שלו עבור הנתונים. קיבלנו שגיאת אימון של כ- 8% ושגיאת הכללה של כ- 12%.

שלב 5: Test the classifier:

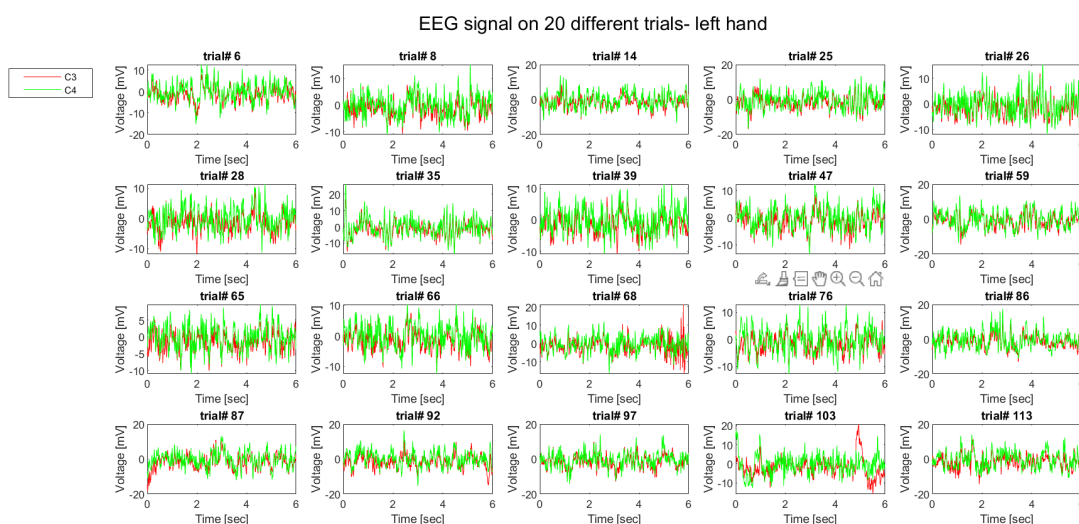
בנוסף לקובץ הנתונים שקיבלנו של הקלטות ה- EEG עם התוויות (דמיון מוטורי של צד ימין או שמאל) קיבלנו קובץ נתונים נוסף של הקלטות באותם תנאים ללא התוויות בכדי שנוכל לבחון את יכולת הסיווג של המסווג שלימדנו. השתמשנו הפעם בכל הנתונים שקיבלנו (128 חזרות) בכדי לאמן את המסווג ובחנו את יכולתו לנבא באיזה צד התרחש הדמיון המוטורי. קיבלנו בפעם הראשונה שגיאת הכללה יחסית גדולה (כ- 20%) אז התאמנו את הפיצ'רים שלנו כל שיחזו טוב יותר על ידי בחירה של פחות פיצ'רים אבל יותר טובים. לבסוף קיבלנו רמת ניבוי של 96%.

תוצאות


גרף 1-וויזואליזציה:

20 דוגמאות אקראיות בהן הנבדק דמיין תנועה ביד שמאל/ ימין. ציר ה- x מסמן את הזמן בשניות וציר ה- y את עוצמת הסיגנל ב-mV. אלקטרודה C3 מיוצגת בצבע אדום ואלקטרודה C4 מיוצגת בצבע ירוק.

גרף 1.1- ביד שמאל

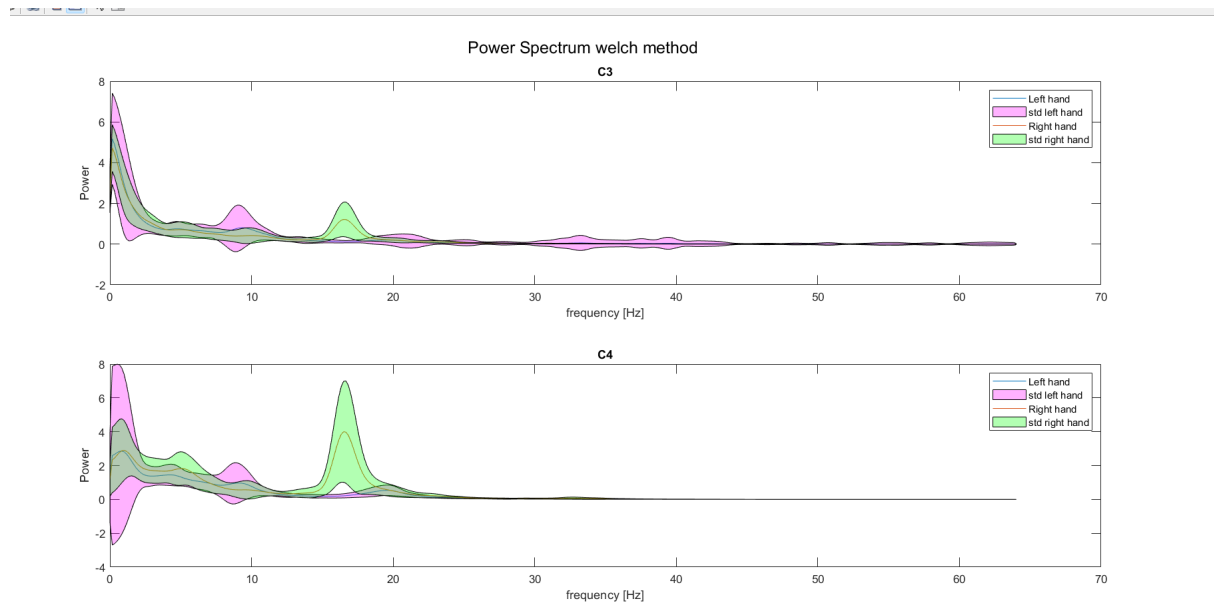


גרף 1.2- ביד ימין



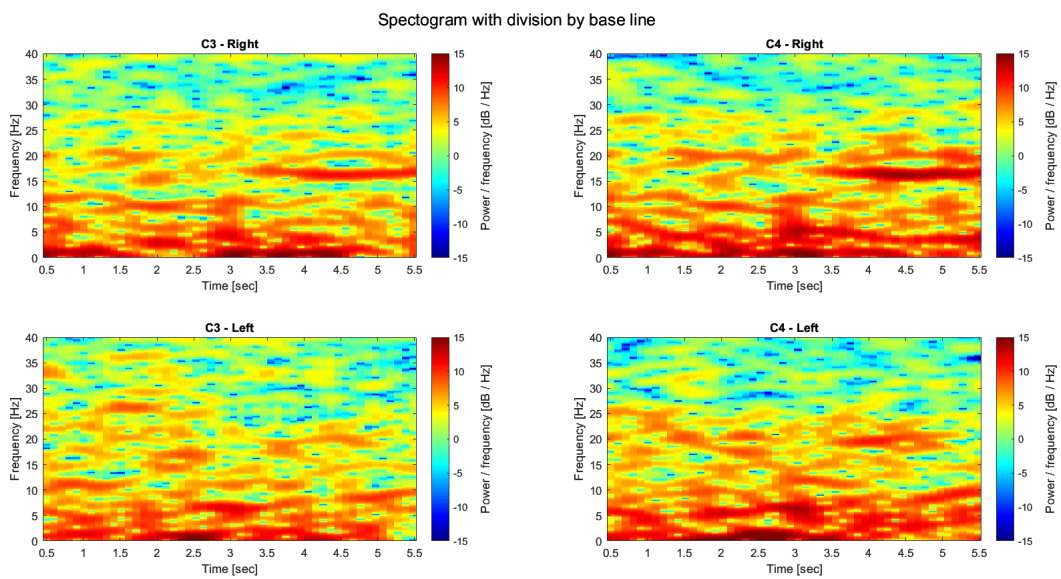
גרף 2- Power Spectra:

גרפים אלו מייצגים את ה- power spectra עבור 2 האלקטרודות: C3, C4. כאשר בכל גרף יש 2 עקומות עבור יד ימין/ שמאל ואת סטיית התקן כל עקומה.

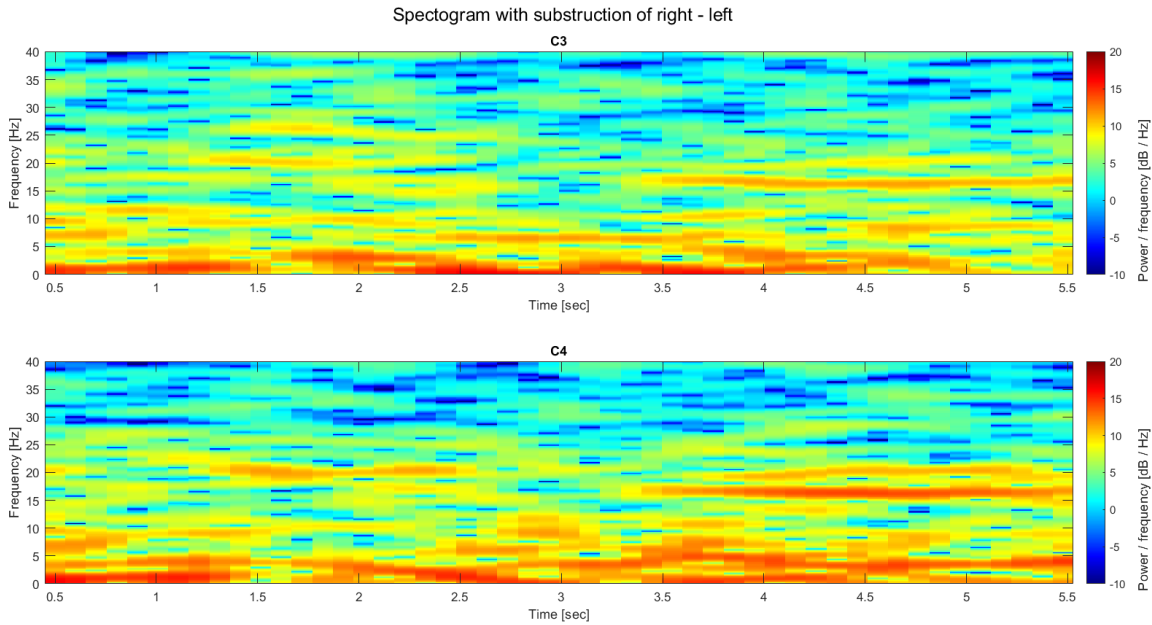


גרף 3-Power spectrogram:

גרף 3.1: גרפים אלו מייצגים את עוצמת התדר בכל תדירות (0-40 Hz)- ציר Y לפי זמן- ציר X בכל תנאי ומכל אלקטרודה.



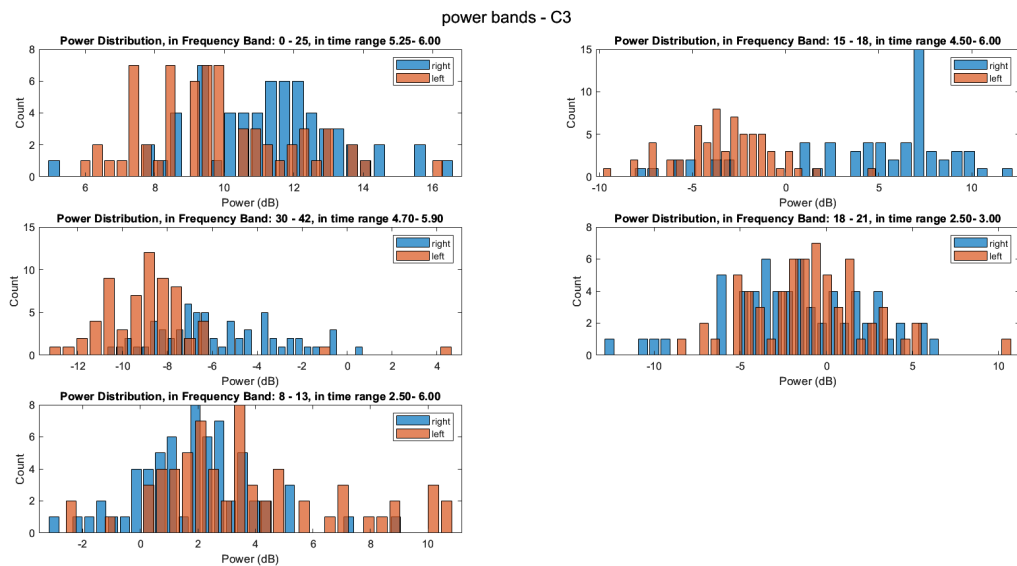
גרף 3.2 - גרפים אלו מייצגים את חיסור טווח העוצמות של תנאי שמאל מימין.



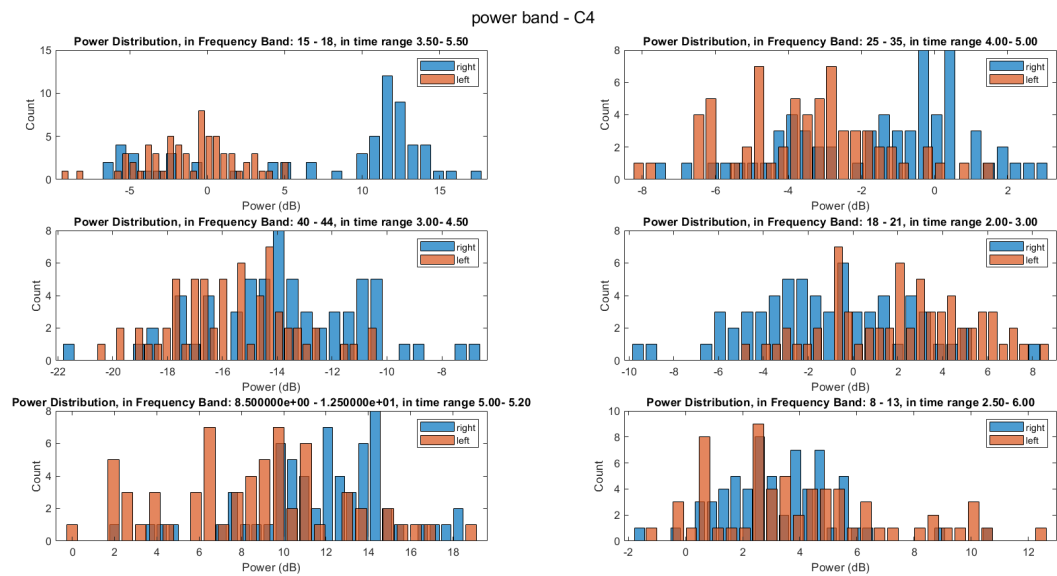
גרף 4-Power bands:

כל גרף מייצג את ההבדלים בעוצמת רצועות תדרים נבחרים במקטעי זמן ספציפיים. ציר X מסמל את ה-Power וציר ה-Y את מספר הערכים התואמים ערך זה.

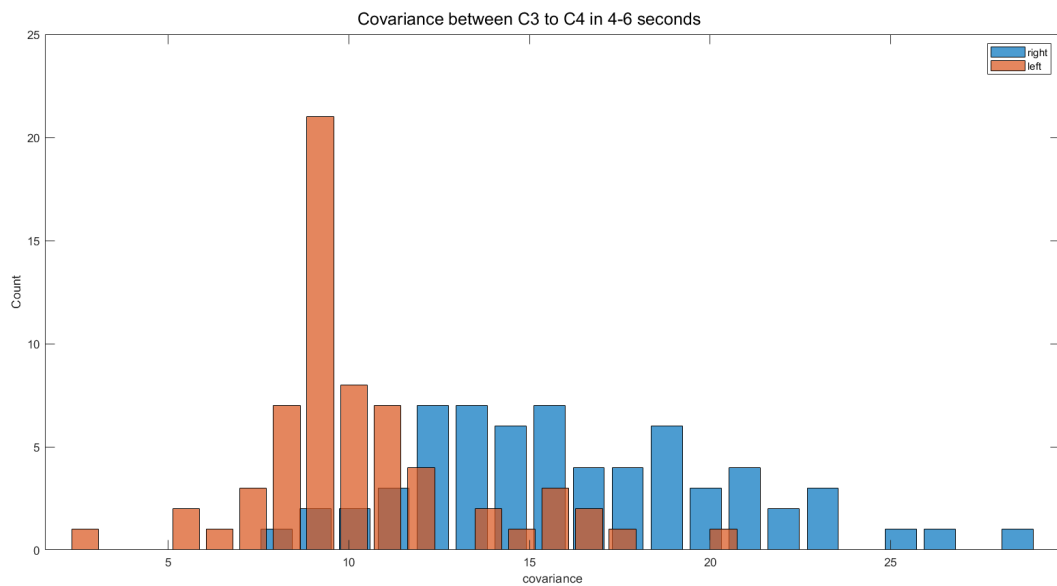
גרף 4.1 - באלקטרודה C3





גרף 4.2- באלקטרודה C4




גרף 4.3- שונות משותפת בין C3 ל- C4. ציר X מסמל את מידת השונות המשותפת בין 2 האלקטרודות ביד ימין בכחול וביד שמאל באדום וציר ה-Y את מספר הערכים התואמים ערך זה.



גרף 4.4- spectral entropy נמדדה ב-2 האלקטרודות בטווחי זמן שונים, עבור 2 הידיים, יד ימין בכחול ויד שמאל באדום. ציר ה-X מסמל את מידת ה-spectral entropy וציר ה-Y את מספר הערכים התואמים ערך זה.



גרף 5.-PCA

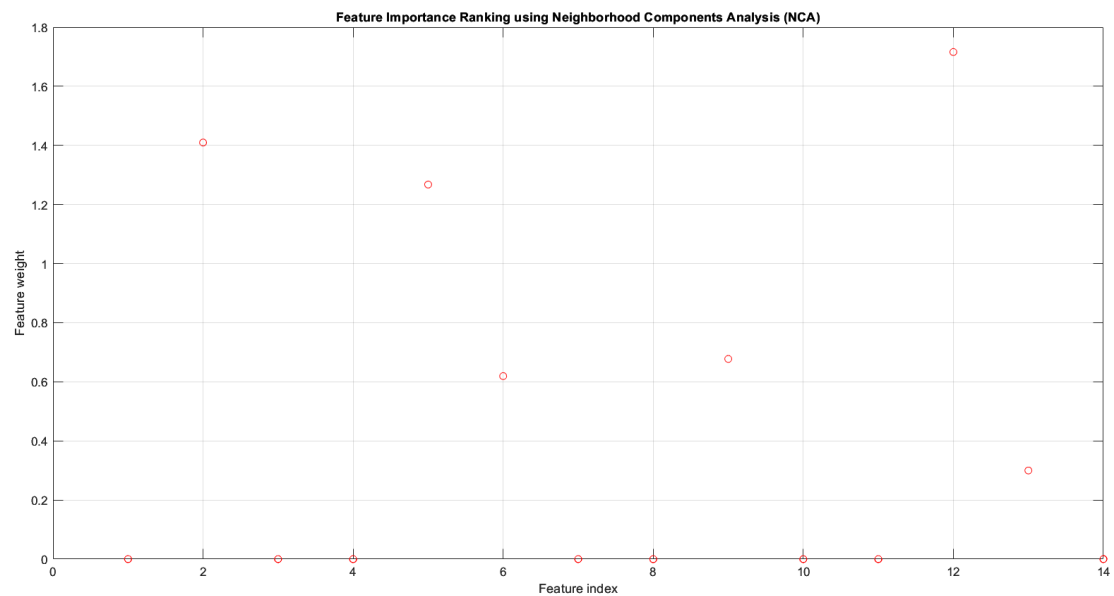


הגרפים מתארים פיזור בשיטת PCA ב-2 מימד ובתלת מימד לפי הפיצורים המשמעותיים ביותר.

גרף 6-NCA:

חלוקת יעילות הפיצ'רים בשיטת NCA.

גרף 6.1- ניתן לראות בצורת גרפים את משקל יעילותו של כל פיצ'ר .



גרף 6.2- טבלה המסדרת את המסווגים לפי רמת יעילותם, יחד עם שמם ועם רמת החשיבות שלהם.

Command Window		
Num	Feature	Importance
1	{'covariance' }	1.716
2	{'powerBandC3_2' }	1.4098
3	{'powerBandC3_5' }	1.2674
4	{'powerBandC4_4' }	0.67736
5	{'powerBandC4_1' }	0.61929
6	{'spectral_entropy_c3'}	0.29986
7	{'powerBandC3_1' }	0.00016017
8	{'powerBandC3_3' }	5.4971e-05
9	{'powerBandC4_6' }	1.4574e-05
10	{'powerBandC4_5' }	8.9601e-06
11	{'powerBandC4_3' }	8.7388e-06
12	{'powerBandC4_2' }	6.9876e-06

דיון

כללי:

המוח מחולק לשתי המיספרות, ימנית ושמאלית, כאשר התקשורת בין ההמיספרות נעשה בקורפוס קלזום. השליטה בגפיים וספציפית בידיים נעשית באופן קונטרה-לטרלי. כלומר, בעת הפעלת צד ימין נצפה לאקסיטציה בצד שמאל ולהיפך. לכן, בעבודה זו, בה הקלטות EEG נלקחו מאלקטרודות C3 ו-C4, הנמצאות באיזור השליטה המוטורית (precentral gyrus), נייחס את ה"שליטה" בצד הימני לאלקטרודה C3 ואת ה"שליטה" בצד שמאל לאלקטרודה C4. הוכח שדימויים מוטוריים מובילים להפעלה של אותם אזורי מוח כמו תנועה בפועל (J Neural Transm. 2007) וכיום משתמשים בדימיון מוטורי לשיקום נירונלי ולשיפור יכולות (למשל בקרב ספורטאים). לכן, נבחן את הרכיבים שיעזרו לנו להבחין ולסווג בין דמיון הפעלת יד ימין ליד שמאל.

גלי אלפא:

אקסיטציה של גלי האלפא (8-13 Hz) מקושרת בדרך כלל למצב מוח רגוע, למשל, עצימת עיניים. במהלך צילום מוטורי היינו מצפות להבחין באינהיביציה בגלי אלפא באיזור השליטה המוטורית (הכולל אלקטרודות C3 ו-C4) כאשר הנבדק מדמיון תזוזה של יד ימין או שמאל. לדוגמה, אם הנבדק היה מדמיון תזוזה של יד ימין היינו מצפות לראות אינהיביציה באלקטרודה C3. בהתאם לציפיותינו ניכר הבדל משמעותי בין יד ימין לשמאל בעיקר באלקטרודה C3 (גרף 4.1 תמונה 5), המסווג השלישי ביעילותו. עם זאת באלקטרודה C4 השינוי היה פחות משמעותי, ייתכן ששונות זו נובעת מהבדלים שמקורם ביד הדומיננטית של הנבדק. מכאן נסיק שבעת אינהיביציה של גלי אלפא בצד הקונטרה-לטרלי ליד מסוימת ירמז על הפעלתה/ דמיון הפעלתה.

גלי בטא:

גלי בטא (16-30 Hz) מקושרת לתכנון וביצוע מוטורי. במקרה זה נתמקד בתדרים 15-18 Hz הנכללים בתדר הבטא. נבחין כי באלקטרודה C3 הייתה אקסיטציה של תדרים אלו במהלך דימוי מוטורי של תנועת יד ימין, כפי שציפנו (גרף 4.1 תמונה 2), המסווג השני היעיל ביותר. בהתאם לזאת, ציפינו לראות אקסיטציה של אלקטרודה C4 בעת דימוי מוטורי של יד שמאל (גרף 4.2 תמונה 1) המסווג החמישי ביעילותו. עם זאת, נצפתה אקסיטציה מוגברת באלקטרודה C4 דווקא בעת דימוי מוטורי של יד ימין. במחקרו של זפאלה ושותפיו (Zapala, D et al, 2021) חיפשו כיצד הצד הדומיננטי משפיע על הפעילות של תנודות אלפא (8-13 הרץ) ובטא (15-30 הרץ) במהלך יצירת ייצוג קינסטטי (KMI) או ויזואלי-מוטורי (VMI) של תנועה. בניסוי אכן גילו כי קיימת שונות בין ימנים לשמאליים, ואצל ימנים אכן קיים הבדל בין תפקודי החלק הימני לשמאלי באיזור הקורטקס המוטורי. נסיק כי ייתכן ושונות זו מגיעה מנתון זה ולכן נראה אקסיטציה גם בצד הלטרלי בעת הפעלת היד הדומיננטית (בהנחה שהיד הדומיננטית של הנבדק היא יד ימין).

גלי גמא:

בהתאם לציפיותנו לא ראינו הבדלים משמעותיים בגלי הגמא (30-100 Hz). גלי גמא ככל הנראה משתתפים בפעילות הקשורה לתהליכים קוגניטיביים מסדר גבוה וליכולת ריכוז מוגברת (באופן כללי). מכיוון שהמשימה היא מסדר נמוך ולא מצריכה יכולת ריכוז מרבית לא צפינו לראות שינויים משמעותיים. ואכן כפי שניתן לראות בגרף 4.1 תמונה 3- המייצג את הפעילות באלקטרודה C3 ומגרף 4.2 תמונה 3 המייצגים את הפעילות ב-C4, המייצגים את המסווגים הממויינים לפי יעילותם במקומות ה-8,11 ולא נכנסים לתהליך הלמידה הסופי- לא נצפה שינוי משמעותי.

Covariance:

ידוע שאלקטרודות C3 ו-C4, נמצאות באיזור השליטה המוטורית, כאשר כל אחת מהן "אחראית" על השליטה בצד הקונטרא לטרלי ובנוסף התקשורת בין שתי ההמיספרות עוברת בקורפוס קלוזום. כיום ידוע כי על אף שקיימים איזורים במוח האחראים על פונקציות שונות, קיימת תקשורת בין חלקים נוספים בעת ביצוע הפונקציה. לכן, בעת משימת דימוי מוטורי נצפה לקבל שונות משותפת בין שתי האלקטרודות מתוך ההנחה כי בעקבות ביצוע המשימה מתרחשים שינויים באיזור הקורטקס המוטורי בשני הצדדים. ואכן, מסווג NCA סיווג את תכונת השונות המשותפת במסווג הטוב ביותר (מקום 1 מבחינת יעילות סיווג).

Spectral entropy:

spectral entropy היא מדד המכמת את המורכבות או האקראיות של אותות EEG על פני טווחי תדרים שונים. בעת בחינת דימויים מוטוריים בין יד ימין לשמאל, היינו מצפות לראות הבדלים באנטרופיה הספקטרלית עקב הפעילות העצבית הבסיסית הקשורה לתהליכים המוטוריים, במקרה זה היינו מצפות לראות למשל עליה באנטרופיה באלקטרודה C3 בעת הפעלת היד הקונטרה לטרלית. ניכר כי בעת הפעלת יד ימין האנטרופיה הספקטרלית הייתה גבוהה יותר בשתי האלקטרודות (גרף 4.4), עם זאת, בהתאם לציפיותינו באלקטרודה C3 ניכר שהאנטרופיה הייתה גדולה יותר באופן משמעותי יותר בהפעלת שתי הידיים מאשר באלקטרודה C4. אין לנו תשובה חד משמעית לתופעה זו, אך נוכל להסיק כי המקור להבדל זה נובע מצד דומיננטי של הנבדק שגורם להפעלה משמעותית יותר באופן גורף של ההמיספרה הדומיננטית, במקרה זה ההמיספרה השמאלית. עם זאת, בעת דירוג המסווגים מתברר כי מסווגים אלו לא כל כך יעילים (מקום 6 ו-13). יכול להיות שמקרה זה נובע ממולטי-קולינאריות (Multicollinearity), כאשר לשני משתנים בלתי תלויים או יותר יש קשר ליניארי גבוה מאוד ביניהם, כלומר, יכול להיות שהמסווגים נמצאים בקורלציה גבוהה עם מסווגים אחרים ובעת שימוש בפיצ'רים אלו יחד יכולת החיזוי של האלגוריתם שלנו תרד.

Feature classification:

באופן כללי שימוש בנתונים רבים יותר לאימון אמור להוביל למסווג מדויק וחזק יותר, עם זאת, במידה וקיימים שני פיצ'רים בעלי קורלציה גבוהה ביניהם (Multicollinearity) או פיצ'ר בעת יכולת

מובחנות נמוכה (לא יעיל) הדבר עלול לפגוע בתהליך האימון של האלגוריתם. לכן, השתמשנו ב-NCA (feature selection ללמידה מפוקחת). מטרת המסווג היא למצוא קומבינציה לינארית הממקסמת את הדיוק של אלגוריתם הסיווג שלנו, ע"י לימוד משקלי תכונות המבוססים על התוויות של נתוני האימון, המסוגל להתמודד עם כמות מידע גדולה. בעזרת מסווג ביצענו אינטגרציה של הפיצ'רים היעילים ביותר וכך הגענו לאחוזי דיוק של כ-90%.

לסיכום, לאימון האלגוריתם למשימת הסיווג לא נדרשת כמות גדולה של מסווגים, אלא מסווגים באיכות טובה שבעת האינטגרציה ביניהם יניבו את תוצאות הניסוי המדוייקות ביותר. בעבודה זו גילינו כי רצוי לייצא מגוון מסווגים, החל משימוש בתיאוריה המוכרת לנו של תדרים שונים (אלפא ובטא) וכלה בשונות משותפת, אנטרופיה וכו'. כמו כן, נמליץ להשתמש ב-feature selection ללמידת מכונה מפוקחת על מנת למצוא את אינטגרציית הפיצ'רים האופטימלית.

ביבליוגרפיה

- Fitzpatrick, D., Kaneko, H., & Katz, L. C. (1993). A synaptic basis for associative learning in primary visual cortex. *Nature*, 375(6529), 326-328.
- Mulder T. Motor imagery and action observation: cognitive tools for rehabilitation. *J Neural Transm (Vienna)*. 2007;114(10):1265-78. doi: 10.1007/s00702-007-0763-z. Epub 2007 Jun 20. PMID: 17579805; PMCID: PMC2797860.
- Zapala, D., Iwanowicz, P., Francuz, P., & Augustynowicz, P. (2021). Handedness effects on motor imagery during kinesthetic and visual-motor conditions. *Scientific reports*, 11(1), 13112.